

Raport1

Dagmara Skowron

2026-02-25

Zadanie 1

Celem zadania jest zbadanie wpływu wyników testu rachunkowego (*numeracy*) oraz poziomu niepewności (*anxiety*) na prawdopodobieństwo przyjęcia na studia. Zmienna odpowiedzi Y przyjmuje wartości:

$$Y = \begin{cases} 1 & \text{– przyjęcie na studia,} \\ 0 & \text{– brak przyjęcia.} \end{cases}$$

Dysponujemy zbiorem $n = 50$ niezależnych obserwacji postaci

$$(Y_i, X_{i1}, X_{i2}), \quad i = 1, \dots, 50,$$

gdzie:

$$X_{i1} = \text{numeracy}, \quad X_{i2} = \text{anxiety}.$$

Table 1: Podstawowe informacje o zbiorze danych

Liczba_observacji	Liczba_zmiennych
50	3

Table 2: Pierwsze 6 obserwacji

numeracy	anxiety	success
6.6	13.8	0
7.1	14.6	0
7.3	17.4	0
7.5	14.9	1
7.9	13.4	0
7.9	13.5	1

Zadanie 2

Zależność między wynikiem testu rachunkowego a decyzją o przyjęciu zilustrowano za pomocą wykresów pudełkowych. Wykresy te pozwalają porównać rozkład zmiennej *numeracy* w dwóch grupach:

$$Y = 0 \quad (\text{brak przyjęcia}), \quad Y = 1 \quad (\text{przyjęcie}).$$

Wynik testu rachunkowego a przyjęcie na studia




Table 3: Statystyki opisowe zmiennej numeracy w podziale na grupy

Grupa	Min	Q1	Mediana	Średnia	Q3	Max
0 (nieprzyjęci)	6.6	8.2	9.1	9.12	10.6	11.3
1 (przyjęci)	7.5	10.1	12.4	11.88	13.8	15.7

Na podstawie wykresu pudełkowego widać różnice w rozkładzie zmiennej *numeracy* pomiędzy grupą osób przyjętych na studia a grupą nieprzyjętych.

Mediana wyniku testu rachunkowego w grupie przyjętych wynosi około 12.4, natomiast w grupie nieprzyjętych około 9.1. Oznacza to, że osoby przyjęte osiągały istotnie wyższe wyniki z testu rachunkowego.

Dodatkowo cały rozkład wyników w grupie przyjętych jest przesunięty w kierunku wyższych wartości, co sugeruje dodatnią zależność pomiędzy poziomem umiejętności rachunkowych a prawdopodobieństwem przyjęcia na studia.

Zadanie 3

W kolejnym kroku przeprowadzono analizę zmiennej *anxiety*, opisującej poziom niepewności kandydatów, w podziale na grupę osób przyjętych oraz nieprzyjętych na studia.

Poziom niepewności a przyjęcie na studia




Table 4: Statystyki opisowe zmiennej *anxiety* w podziale na grupy

Grupa	Min	Q1	Mediana	Średnia	Q3	Max
0 (nieprzyjęci)	13.3	14.0	15.8	15.62	16.9	17.7
1 (przyjęci)	10.1	11.4	13.1	12.75	14.0	15.1

Na podstawie wykresu pudełkowego widać różnice w rozkładzie zmiennej *anxiety* pomiędzy grupą osób przyjętych oraz nieprzyjętych na studia.

Mediana poziomu niepewności w grupie nieprzyjętych wynosi około 15.8, natomiast w grupie przyjętych około 13.1. Oznacza to, że osoby nieprzyjęte charakteryzowały się przeciętnie wyższym poziomem niepewności.

Cały rozkład zmiennej *anxiety* w grupie przyjętych jest przesunięty w kierunku niższych wartości, co sugeruje ujemną zależność pomiędzy poziomem niepewności a prawdopodobieństwem przyjęcia na studia.

Zadanie 4

W celu ilościowej oceny wpływu zmiennych *numeracy* oraz *anxiety* na prawdopodobieństwo przyjęcia na studia zastosowano model regresji logistycznej.

Zmienna odpowiedzi Y ma charakter binarny, dlatego przyjęto założenie, że

$$P(Y_i = 1 \mid X_i) = \mu_i,$$

gdzie $\mu_i \in (0, 1)$. Związek pomiędzy prawdopodobieństwem sukcesu a predyktorem liniowym opisano za pomocą funkcji logit:

$$\log\left(\frac{\mu_i}{1-\mu_i}\right) = \beta_0 + \beta_1 \text{numeracy}_i + \beta_2 \text{anxiety}_i.$$


Parametry modelu estymowano metodą największej wiarygodności. W dalszej części analizy przedstawiono estymatory parametrów, wyniki testów istotności, przewidywane prawdopodobieństwo sukcesu dla wybranego kandydata oraz ocenę jakości klasyfikacji z wykorzystaniem krzywej ROC.

Table 5: Wyniki estymacji modelu regresji logistycznej

	Parametr	Estymator	Błąd standardowy	Statystyka z	p-value
(Intercept)	(Intercept)	14.2386	6.7985	2.0944	0.0362
numeracy	numeracy	0.5774	0.2481	2.3272	0.0200
anxiety	anxiety	-1.3841	0.4804	-2.8811	0.0040

Table 6: Przewidywane prawdopodobieństwo sukcesu dla anxiety=13 i numeracy=10

anxiety	numeracy	Przewidywane.P.success.1.
13	10	0.8828



Na podstawie estymacji modelu regresji logistycznej stwierdzono, że zarówno zmienna *numeracy*, jak i *anxiety* mają istotny statystycznie wpływ na prawdopodobieństwo przyjęcia na studia (p -wartość $< 0,05$).

Współczynnik przy zmiennej *numeracy* jest dodatni ($\hat{\beta}_1 = 0,5774$), co oznacza, że wzrost wyniku testu rachunkowego zwiększa log-iloraz szans przyjęcia na studia.

Z kolei współczynnik przy zmiennej *anxiety* jest ujemny ($\hat{\beta}_2 = -1,3841$), co wskazuje na negatywny wpływ poziomu niepewności na prawdopodobieństwo sukcesu. Oznacza to, że wyższy poziom niepewności wiąże się ze spadkiem szans przyjęcia.

Dla studenta o parametrach $numeracy = 10$ oraz $anxietety = 13$ przewidywane prawdopodobieństwo przyjęcia wynosi około 0,883, co wskazuje na wysoką szansę sukcesu.

Pole pod krzywą ROC wynosi

$$AUC = 0,9491,$$

co oznacza bardzo dobrą zdolność modelu do rozróżniania osób przyjętych i nieprzyjętych.

Podsumowując, model regresji logistycznej dobrze opisuje zależność pomiędzy zmiennymi objaśniającymi a prawdopodobieństwem przyjęcia na studia.


Zadanie 5

By sprawdzić wpływ wyboru funkcji linkującej na dopasowanie modelu regresji logistycznej przeprowadzono estymację modeli z różnymi funkcjami linkującymi: logit, probit, cauchit oraz cloglog.

Dla każdego z modeli wyznaczono estymatory parametrów, p-wartości dla poszczególnych współczynników oraz przewidywane prawdopodobieństwo przyjęcia na studia dla studenta o parametrach $anxietety = 13$ oraz $numeracy = 10$. Następnie porównano zdolność klasyfikacyjną modeli na podstawie krzywych ROC.

Table 7: Porównanie modeli z różnymi funkcjami linkującymi

	Funkcja	Est..b0	p.wartosc.b0	Est..b1..numeracy.	p.wartosc.b1	Est..b2..anxietety.	p.wartosc.b2	P.Success.
(Intercept)	logit	14.2386	0.0362	0.5774	0.0200	-1.3841	0.0040	0.8828
(Intercept)1	probit	8.2573	0.0247	0.3371	0.0137	-0.8039	0.0014	0.8806
(Intercept)2	cauchit	18.3830	0.1350	0.7323	0.1224	-1.7741	0.0735	0.8849
(Intercept)3	cloglog	9.0006	0.0530	0.4024	0.0082	-0.9390	0.0047	0.8963



Na podstawie otrzymanych wyników można zauważyć, że wartości estymatorów parametrów dla poszczególnych funkcji linkujących są do siebie zbliżone. W większości przypadków zmienne $numeracy$ oraz $anxietety$ pozostają istotne statystycznie, co potwierdza ich wpływ na prawdopodobieństwo przyjęcia na studia.

Przewidywane prawdopodobieństwo sukcesu dla studenta o parametrach *anxiety* = 13 oraz *numeracy* = 10 jest bardzo podobne dla wszystkich modeli i wynosi około 0,88–0,89.

Porównanie krzywych ROC pokazuje, że wszystkie rozważane modele mają bardzo zbliżoną zdolność klasyfikacyjną, ponieważ krzywe niemal całkowicie się pokrywają. Oznacza to, że wybór funkcji linkującej nie ma istotnego wpływu na jakość dopasowania modelu dla analizowanego zbioru danych.

Zadanie 6

Dla wybranego modelu logitowego przeprowadzono weryfikację stabilności estymacji parametrów. Wykorzystując macierz informacji Fishera, oszacowano macierz kowariancji wektora parametrów.

Następnie przeprowadzono test hipotezy zerowej postaci

$$H_0 : \beta_1 = \beta_2 = 0,$$

co odpowiada weryfikacji, czy zmienne *numeracy* oraz *anxiety* nie mają wpływu na prawdopodobieństwo przyjęcia na studia. Test ten oparto na statystyce ilorazu wiarygodności, porównując model pełny z modelem zredukowanym.

W ostatniej części zadania przeanalizowano wpływ parametru zbieżności *epsilon*, wykorzystywanego w algorytmie iteracyjnego ważonego najmniejszych kwadratów (IRLS). Parametr ten określa tolerancję zbieżności procedury estymacyjnej, a jego wartość domyślna w `glm()` wynosi 10^{-8} . Dokonano ponownej estymacji modelu dla wybranych wartości

$$10^{-1}, 10^{-2}, 10^{-3}, 10^{-6},$$

a następnie porównano liczbę iteracji oraz wartości otrzymanych estymatorów parametrów w celu oceny stabilności numerycznej modelu.

Table 8: Estymator macierzy kowariancji współczynników

	(Intercept)	numeracy	anxiety
(Intercept)	46.2199	-0.2483	-3.0613
numeracy	-0.2483	0.0615	-0.0238
anxiety	-3.0613	-0.0238	0.2308

Table 9: Porównanie odchyłeń standardowych

	Parametr	SE..z.vcov.	SE..z.summary.	Różnica
(Intercept)	(Intercept)	6.798519	6.798519	0
numeracy	numeracy	0.248084	0.248084	0
anxiety	anxiety	0.480403	0.480403	0

Table 10: Test ilorazu wiarygodności dla $H_0: \beta_{numeracy} = \beta_{anxiety} = 0$

Model	St. swob.(resztowe)	Deviance reszt.	Różnica df	Różnica dev	p-wartosc
Model zredukowany: intercept	49	68.02920	NA	NA	NA
Model pełny: numeracy + anxiety	47	28.28562	2	39.74358	0

Table 11: Wpływ parametru zbieżności epsilon na liczbę iteracji i estymatory parametrów

epsilon	iteracje	beta_0	beta_numeracy	beta_anxiety
1e-01	3	12.89008	0.537585	-1.263953
1e-02	4	14.09247	0.573545	-1.371306
1e-03	5	14.23683	0.577314	-1.383920
1e-06	6	14.23858	0.577352	-1.384069

Wyznaczona macierz kowariancji estymatorów parametrów jest zgodna z teoretyczną postacią odwrotności macierzy informacji Fishera. Pierwiastki z elementów diagonalnych tej macierzy są identyczne z odchyleniami standardowymi zwracanymi przez funkcję `summary()`, co potwierdza poprawność implementacji estymacji metodą największej wiarygodności w modelu regresji logistycznej.

Test hipotezy zerowej

$$H_0 : \beta_{numeracy} = \beta_{anxiety} = 0$$

przeprowadzony na podstawie statystyki ilorazu wiarygodności wykazał bardzo silną istotność modelu pełnego względem modelu zredukowanego. Wartość statystyki chi-kwadrat wynosi około 39,74, a p-wartość jest bliska zeru, co prowadzi do odrzucenia hipotezy zerowej. Oznacza to, że co najmniej jedna ze zmiennych objaśniających ma istotny wpływ na prawdopodobieństwo przyjęcia na studia.

Podsumowując, model regresji logistycznej z funkcją linkującą logit jest stabilny, a zmienne *numeracy* oraz *anxiety* mają istotny wpływ na zmienną odpowiedzi.

Symulacje

Podpunkt 1

Wygenerowano macierz $X \in \mathbb{R}^{n \times p}$ o wymiarach $n = 400$ oraz $p = 3$, której elementy są niezależnymi zmiennymi losowymi z rozkładu normalnego

$$X_{ij} \sim \mathcal{N}\left(0, \frac{1}{400}\right).$$

Założono, że wektor odpowiedzi binarnej generowany jest zgodnie z modelem regresji logistycznej

$$P(Y_i = 1 \mid X_i) = \frac{\exp(X_i^\top \beta)}{1 + \exp(X_i^\top \beta)},$$

gdzie

$$\beta = (3, 3, 3)^\top.$$

W pierwszym kroku wyznaczono macierz informacji Fishera w punkcie β oraz asymptotyczną macierz kowariancji estymatorów największej wiarygodności. Następnie przeprowadzono 1000 replikacji generowania wektora odpowiedzi i estymacji parametru β , co pozwala empirycznie zbadać rozkład estymatorów, ich obciążenie oraz macierz kowariancji i porównać je z wynikami asymptotycznymi.

1) n=400, p=3




Table 12: Macierz informacji Fishera $J((\beta))$

0.2280	0.0030	-0.0024
0.0030	0.2824	-0.0008
-0.0024	-0.0008	0.2619

Table 13: Asymptotyczna macierz kowariancji $J(\beta)^{-1}$

4.386740	-0.045993	0.040631
-0.045993	3.541634	0.010483
0.040631	0.010483	3.818472

Table 14: Własności estymatorów:

Parametr	Wartość prawdziwa	Średnia estymatora	Obciążenie	SD est.	SD asympt.
beta_1	3	3.053154	0.053154	2.161518	2.094455
beta_2	3	2.989344	-0.010656	1.895594	1.881923
beta_3	3	3.007482	0.007482	1.994920	1.954091

Table 15: Macierz kowariancji estymatorów

4.672160	-0.063299	-0.188733
-0.063299	3.593276	0.055958
-0.188733	0.055958	3.979706

Table 16: Macierz kowariancji asymptotyczna

4.386740	-0.045993	0.040631
-0.045993	3.541634	0.010483
0.040631	0.010483	3.818472

Na podstawie przeprowadzonej symulacji dla $n = 400$ oraz $p = 3$ można stwierdzić, że estymatory największej wiarygodności w modelu regresji logistycznej wykazują bardzo dobre własności asymptotyczne.

Histogramy estymatorów $\hat{\beta}_1$, $\hat{\beta}_2$ oraz $\hat{\beta}_3$ są zbliżone do rozkładu normalnego. Potwierdza to asymptotyczną normalność estymatorów MLE.

Średnie wartości estymatorów są bardzo bliskie wartościom rzeczywistym $\beta = (3, 3, 3)$.

Podsumowując, dla stosunkowo dużej próby estymatory największej wiarygodności w regresji logistycznej są stabilne.

Podpunkt 2

W drugim etapie badania analizowany jest wpływ liczby obserwacji na własności estymatorów największej wiarygodności w modelu regresji logistycznej. W tym celu powtórzono eksperyment, zmniejszając liczebność próby do $n = 100$, przy zachowaniu liczby regresorów $p = 3$ oraz wektora parametrów $\beta = (3, 3, 3)^\top$.

2) $n=100$, $p=3$




Table 17: Własności estymatorów

Parametr	Wartość prawdziwa	Średnia estymatora	Obciążenie	SD est.	SD asympt.
beta_1	3	3.047639	0.047639	1.943349	1.827816
beta_2	3	3.088530	0.088530	2.246868	2.136593
beta_3	3	3.113377	0.113377	2.104774	1.990467

Zmniejszenie liczby obserwacji do $n = 100$ powoduje pogorszenie własności estymatorów w porównaniu z ($n = 400$).

Histogramy estymatorów nadal mają kształt zbliżony do rozkładu normalnego. Odchylenia standardowe estymatorów są nieco większe niż w przypadku większej próby, co wskazuje na spadek precyzji estymacji.

Obciążenie estymatorów pozostaje stosunkowo niewielkie, jednak jest większe niż w $n = 400$.

Podsumowując, zmniejszenie liczebności próby prowadzi do wzrostu wariancji estymatorów i wolniejszej zbieżności do rozkładu asymptotycznego.

Podpunkt 3

W trzecim etapie badania analizowany jest wpływ zależności pomiędzy zmiennymi objaśniającymi na własności estymatorów największej wiarygodności w modelu regresji logistycznej.

W tym celu przyjęto, że wiersze macierzy X są niezależnymi wektorami losowymi z wielowymiarowego rozkładu normalnego

$$X_i \sim \mathcal{N}(0, \Sigma),$$

gdzie

$$\Sigma = \frac{1}{n}S, \quad S_{ii} = 1, \quad S_{ij} = 0,3 \text{ dla } i \neq j.$$

3) n=400, p=3, rho=0.3




Table 18: Własności estymatorów

Parametr	Wartość prawdziwa	Średnia estymatora	Obciążenie	SD est.	SD asympt.
beta_1	3	3.023321	0.023321	2.302742	2.229055
beta_2	3	3.057062	0.057062	2.250282	2.178105
beta_3	3	3.040478	0.040478	2.208419	2.158384

Wprowadzenie dodatniej korelacji pomiędzy zmiennymi objaśniającymi ($\rho = 0,3$) nie powoduje istotnego obciążenia estymatorów — średnie wartości $\hat{\beta}_i$ pozostają bardzo bliskie wartości rzeczywistej $\beta_i = 3$, a oszacowane obciążenia są niewielkie.

Widoczny jest jednak wzrost odchyleń standardowych estymatorów. Oznacza to spadek precyzji estymacji, co jest konsekwencją współliniowości między zmiennymi objaśniającymi.

Podsumowując, korelacja między regresorami nie wpływa na nieobciążoność estymatorów, lecz prowadzi do wzrostu ich wariancji.

Podpunkt 4

W czwartym etapie analizy badany jest wpływ liczby zmiennych objaśniających na własności estymatorów największej wiarygodności w modelu regresji logistycznej.

W tym celu powtórzono eksperyment, przyjmując $n = 400$ oraz zwiększając liczbę regresorów do $p = 20$. Elementy macierzy X generowane są jako niezależne zmienne losowe z rozkładu

$$X_{ij} \sim \mathcal{N}\left(0, \frac{1}{n}\right),$$

a wektor parametrów przyjęto w postaci

$$\beta = (3, 3, \dots, 3)^\top \in \mathbb{R}^{20}.$$




Table 19: Własności estymatorów

Parametr	Wartość prawdziwa	Średnia estymatora	Obciążenie	SD est.	SD asympt.
beta_1	3	3.169237	0.169237	2.399743	2.212047
beta_2	3	3.261096	0.261096	2.423624	2.213093
beta_3	3	3.259124	0.259124	2.260349	2.148522
beta_4	3	3.140685	0.140685	2.292360	2.182965
beta_5	3	3.103828	0.103828	2.301033	2.182028
beta_6	3	3.106195	0.106195	2.256840	2.167753

Zwiększenie liczby regresorów do $p = 20$ przy stałej liczbie obserwacji $n = 400$ prowadzi do pogorszenia własności estymatorów.

Histogramy estymatorów nadal wskazują na przybliżoną normalność rozkładów, jednak widoczny jest wzrost zmienności estymatorów. Odchylenia standardowe są większe niż w przypadku mniejszej liczby parametrów, co oznacza spadek precyzji estymacji.

Obciążenie estymatorów pozostaje stosunkowo niewielkie. Empiryczne odchylenia standardowe są zbliżone do wartości asymptotycznych.

Podsumowując, zwiększenie liczby parametrów przy stałej liczbie obserwacji powoduje wzrost wariancji estymatorów.

Podpunkt 5

Table 20: Porównanie wariantów (dla $\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$)

Wariant	n	p	Korelacja	Obciążenie b1	SD b1	Obciążenie b2	SD b2	Obciążenie b3	SD b3
1) n=400, p=3	400	3	brak	0.0532	2.1615	-0.0107	1.8956	0.0075	1.9949
2) n=100, p=3	100	3	brak	0.0476	1.9433	0.0885	2.2469	0.1134	2.1048
3) n=400, p=3, rho=0.3	400	3	rho=0.3	0.0233	2.3027	0.0571	2.2503	0.0405	2.2084
4) n=400, p=20	400	20	brak	0.1692	2.3997	0.2611	2.4236	0.2591	2.2603

Wnioski:

Zmniejszenie liczby obserwacji ($n = 100$) prowadzi do wzrostu obciążenia oraz wariancji estymatorów w porównaniu z wariantem bazowym ($n = 400$). Potwierdza to, że większa liczba danych poprawia stabilność i precyzję estymacji.

Wprowadzenie umiarkowanej korelacji między regresorami ($\rho = 0,3$) nie wpływa istotnie na obciążenie estymatorów, jednak powoduje wzrost ich wariancji, co jest konsekwencją współliniowości.

Najsilniejszy efekt obserwowany jest przy zwiększeniu liczby regresorów do $p = 20$. W tym przypadku wyraźnie rośnie łączna wariancja estymatorów, co wskazuje na spadek efektywności estymacji przy stałej liczbie obserwacji. Oznacza to, że wraz ze wzrostem wymiaru modelu maleje ilość informacji przypadająca na pojedynczy parametr.

Podsumowując, estymatory są asymptotycznie nieobciążone i normalne, jednak ich precyzja silnie zależy od liczby obserwacji, współliniowości regresorów oraz relacji między liczbą parametrów a liczebnością próby.