

Raport 2

Dagmara Skowron

2026-03-14

Wstęp

Celem raportu jest analiza liczby klientów odwiedzających sklep w kolejnych godzinach dnia na podstawie danych z około trzech miesięcy. W zbiorze znajdują się informacje o liczbie obsłużonych klientów, dniu tygodnia, godzinie oraz o tym, czy w danym dniu miało miejsce wydarzenie sportowe.

Do analizy wykorzystamy **regresję Poissona**, ponieważ zmienna objaśniana `no.klients` opisuje liczbę zdarzeń w jednostce czasu, czyli liczbę klientów przypadającą na daną godzinę.

Zadanie 1

W zbiorze występują następujące kolumny:

- `no.klients` – liczba klientów obsłużonych w danej godzinie,
- `day` – dzień tygodnia,
- `hour` – godzina,
- `events` – informacja o wydarzeniu sportowym.


Zadanie 2

Na początku przeprowadzamy wstępną analizę danych, aby sprawdzić, czy liczba klientów zależy od godziny dnia, dnia tygodnia oraz występowania wydarzenia sportowego.

Zmienną objaśnianą jest liczba klientów w danej godzinie, natomiast zmienne *hour*, *day* oraz *events* traktujemy jako potencjalne predyktory.


W celu oceny tych zależności przedstawiamy wykresy pudełkowe oraz wykresy ilustrujące zależność liczby klientów od godziny z rozbiciem na dzień tygodnia i wydarzenia sportowe.

Liczba klientów w zależności od godziny




Na podstawie wykresu y względem godziny można zauważyć, że liczba klientów wyraźnie zależy od pory dnia. Największe wartości mediany występują w godzinach popołudniowych, szczególnie w przedziale około 16 : 00–19 : 59, co sugeruje większy ruch klientów w tym czasie. W godzinach wcześniejszych liczba klientów jest wyraźnie mniejsza.

Liczba klientów w zależności od dnia tygodnia



W przypadku zależności y od dnia tygodnia widać, że w dni robocze liczba klientów jest wyższa i bardziej zróżnicowana. Natomiast w weekend wartości są wyraźnie niższe oraz mają mniejszy rozrzut, co sugeruje bardziej równomierny napływ klientów.


Liczba klientów w zależności od wydarzenia sportowego




Wykres względem zmiennej *events* pokazuje, że rozkłady liczby klientów dla *events* = 0 oraz *events* = 1 są do siebie bardzo zbliżone. Różnice w medianach i rozrzucie są niewielkie, co sugeruje, że wydarzenia sportowe nie mają istotnego wpływu na liczbę klientów w sklepie.

Teraz tworzymy wykres pokazujący zależność między godziną a liczbą klientów, z rozbiciem na dzień tygodnia i wydarzenie sportowe.

Liczba klientów w zależności od godziny, dnia i wydarzenia





Wnioski:


Na podstawie wykresów można zauważyć, że liczba klientów wyraźnie zależy od godziny dnia. Największy ruch występuje w godzinach popołudniowych, szczególnie w przedziale około 16 : 00–19 : 00.

Widoczna jest również różnica pomiędzy dniami tygodnia. W dni robocze liczba klientów jest większa i bardziej zróżnicowana, natomiast w weekend liczba klientów jest niższa i bardziej wyrównana.


Porównując *events* = 0 oraz *events* = 1 można zauważyć, że rozkłady są bardzo podobne. Sugeruje to, że wydarzenia sportowe nie mają istotnego wpływu na liczbę klientów.

Kolejne dwa wykresy przedstawiają zależność *y* od godziny w rozbiciu na dzień tygodnia.

Liczba klientów w zależności od godziny



Liczba klientów w kolejnych dniach tygodnia



Wnioski:

Na podstawie wykresów można zauważyć, że liczba klientów wyraźnie zależy od godziny dnia. Największe wartości pojawiają się w godzinach popołudniowych.

W dni robocze liczba klientów jest wyższa oraz bardziej zróżnicowana w ciągu dnia. Natomiast w weekend liczba klientów jest wyraźnie niższa i bardziej wyrównana.

Można również zauważyć, że w weekend rozkład liczby klientów jest stosunkowo stabilny w różnych godzinach dnia, co sugeruje bardziej jednolity napływ klientów.

Zadanie 3

Celem tego zadania jest zbudowanie pełnego modelu regresji Poissona, który uwzględnia wszystkie dostępne predyktory: *day*, *hour* oraz *events* wraz z ich interakcjami.

Zmienną zależną jest liczba klientów obsłużonych w danej godzinie.

Zakładamy, że:

$$Y_i \sim \text{Poisson}(\lambda_i),$$

gdzie λ_i oznacza oczekiwaną liczbę klientów dla danej obserwacji.

Model przyjmuje postać:

$$\log(\lambda_{ijk}) = \beta_0 + \beta_i^{(day)} + \beta_j^{(hour)} + \beta_k^{(events)} + \text{interakcje},$$

co oznacza, że uwzględnione są zarówno efekty główne zmiennych, jak i ich interakcje.

Table 1: Podsumowanie liczby parametrów w modelu Poissona

Miara	Wartosc
Liczba parametrów w modelu	224
Liczba parametrów związanych z events	112

Test istotności zmiennej events

W kolejnym kroku sprawdzamy, czy zmienna *events* oraz jej interakcje z pozostałymi predyktorami mają istotny wpływ na liczbę klientów.

Rozważamy następujące hipotezy:

H_0 : Model bez zmiennej *events* (oraz jej interakcji) jest wystarczający.

H_1 : Model uwzględniający zmienną *events* i jej interakcje lepiej opisuje dane.

Do porównania modeli wykorzystujemy test ilorazu wiarygodności oparty na różnicy dewiacji modeli:

$$\chi^2 = D(M_0) - D(M_1),$$

gdzie $D(M_0)$ oznacza dewiację modelu spełniającego hipotezę zerową, natomiast $D(M_1)$ jest dewiacją modelu pełnego.

Statystykę testową oraz p-wartość obliczamy przy pomocy funkcji `anova()`.

Table 2: Wynik testu ilorazu wiarygodności dla zmiennej events

Porownanie	Chi.kwadrat	df	p.wartość
Model bez events vs model pełny	116.13	112	0.3755

Wnioski

Na podstawie wyniku testu ilorazu wiarygodności otrzymujemy statystykę testową $\chi^2 = 116.13$ przy $df = 112$ oraz wartość $p = 0.3755$.

Ponieważ $p > 0.05$, nie ma podstaw do odrzucenia hipotezy zerowej H_0 . Oznacza to, że model bez zmiennej *events* (oraz jej interakcji) opisuje dane równie dobrze jak model pełny.

Test istotności interakcji

W kolejnym kroku sprawdzamy, czy interakcje pomiędzy zmiennymi *day*, *hour* oraz *events* mają istotny wpływ na liczbę klientów.

Rozważamy następujące hipotezy:

H_0 : Model bez interakcji jest wystarczający.

H_1 : Uwzględnienie interakcji między *day*, *hour* oraz *events* poprawia dopasowanie modelu.

Do porównania modeli wykorzystujemy test ilorazu wiarygodności. Statystyka testowa ma postać

$$\chi^2 = D(M_0) - D(M_1),$$

gdzie $D(M_0)$ oznacza dewiację modelu spełniającego hipotezę zerową, natomiast $D(M_1)$ jest dewiacją modelu zawierającego interakcje.

Przy założeniu prawdziwości hipotezy zerowej statystyka testowa ma asymptotycznie rozkład χ^2 .

Table 3: Wynik testu ilorazu wiarygodności dla interakcji

Porównanie	Chi.kwadrat	df	p.wartość
Model bez interakcji vs model pełny	1051.57	201	0

Wnioski

Ponieważ wartość p jest bardzo mała ($p < 0.05$), odrzucamy hipotezę zerową H_0 . Oznacza to, że interakcje między zmiennymi *day*, *hour* oraz *events* istotnie poprawiają dopasowanie modelu i powinny zostać uwzględnione w dalszej analizie.

Zadanie 4

W kolejnym kroku upraszczamy opis zmiennych objaśniających. Tworzymy dwie nowe zmienne: pierwsza informuje, czy dany dzień jest dniem roboczym czy weekendowym, a druga grupuje godziny w bloki czterogodzinne.

Na podstawie tych nowych zmiennych budujemy model regresji Poissona z interakcją. Następnie sprawdzamy, ile parametrów zawiera nowy model oraz czy różni się on statystycznie od modelu z poprzedniego zadania.

Table 4: Liczba parametrów w nowym modelu Poissona

Miara	Wartosc
-------	---------

Liczba parametrów w nowym modelu	8
Liczba zmiennych objaśniających w nowym modelu	7

Table 5: Porównanie nowego modelu z modelem pełnym

Porównanie	Chi.kwadrat	df	p.wartość
Nowy model vs model pełny	192.85	216	0.8694

Table 6: Porównanie modeli na podstawie AIC i BIC

Model	df	AIC	BIC
Model pełny	224	9185.50	10369.00
Nowy model	8	8946.36	8988.62

Wnioski

Nowy model zawiera znacznie mniej parametrów niż model pełny (8 parametrów zamiast 224), co wynika z pogrupowania dni tygodnia na dni robocze i weekend oraz godzin na cztery bloki czasowe.

Na podstawie testu ilorazu wiarygodności otrzymujemy $p = 0.8694 > 0.05$, dlatego nie ma podstaw do odrzucenia hipotezy zerowej. Oznacza to, że nowy model nie różni się istotnie statystycznie od modelu pełnego.

Dodatkowo wartości kryteriów informacyjnych są niższe dla nowego modelu ($AIC = 8946.36$, $BIC = 8988.62$) niż dla modelu pełnego, co wskazuje na jego lepsze dopasowanie.

Zadanie 5

Na podstawie modelu z zadania 4 konstruujemy tabelę dla podgrup wyznaczonych przez zmienne *typ_dnia* oraz *blok_godzin*. Predyktor liniowy ma postać

$$\eta_i = \hat{\beta}_0 + \sum_{j \in A} \hat{\beta}_j,$$

gdzie zbiór A odpowiada zmiennym przyjmującym wartość 1 dla danej podgrupy.

Table 7: Tabela dla podgrup wyznaczonych przez model z zadania 4

Podgrupa	Średnia liczba klientów	Postać predyktora	Wartość predyktora
dzień roboczy 8:00-11:59	30.01	$\hat{\beta}_0$	3.4015
dzień roboczy 12:00-15:59	19.71	$\hat{\beta}_0 + \hat{\beta}_2$	2.9812
dzień roboczy 16:00-19:59	59.64	$\hat{\beta}_0 + \hat{\beta}_3$	4.0884
dzień roboczy 20:00-23:59	29.98	$\hat{\beta}_0 + \hat{\beta}_4$	3.4006
dzień weekendowy 8:00-11:59	14.79	$\hat{\beta}_0 + \hat{\beta}_{weekend}$	2.6938
dzień weekendowy 12:00-15:59	14.95	$\hat{\beta}_0 + \hat{\beta}_{weekend} + \hat{\beta}_2 + \hat{\beta}_{weekend:2}$	2.7048
dzień weekendowy 16:00-19:59	14.87	$\hat{\beta}_0 + \hat{\beta}_{weekend} + \hat{\beta}_3 + \hat{\beta}_{weekend:3}$	2.6990
dzień weekendowy 20:00-23:59	14.38	$\hat{\beta}_0 + \hat{\beta}_{weekend} + \hat{\beta}_4 + \hat{\beta}_{weekend:4}$	2.6655

Wnioski

Na podstawie tabeli można zauważyć, że liczba klientów jest wyraźnie większa w dniach roboczych niż w weekend. Największe wartości średniej liczby klientów oraz predyktora liniowego występują w dni robocze w godzinach 16 : 00–19 : 59.

W weekend liczba klientów jest znacznie niższa i bardziej wyrównana pomiędzy poszczególnymi blokami godzin, co wskazuje na bardziej jednostajny napływ klientów w ciągu dnia.

Wartości predyktora liniowego η są zgodne z obserwowanymi średnimi, co potwierdza dobre dopasowanie modelu do danych.

Zadanie 6

Na podstawie wcześniejszej analizy przypuszczamy, że w weekend liczba klientów jest podobna w różnych blokach godzin.

Oznacza to, że predyktory liniowe η dla weekendowych podgrup mogą być sobie równe.

Testujemy hipotezę:

$$H_0 : \eta_1 = \eta_2 = \eta_3 = \eta_4$$

przeciwko alternatywie, że przynajmniej jeden z predyktorów liniowych różni się od pozostałych.

Do weryfikacji hipotez wykorzystujemy test Walda.

Table 8: Test Walda dla porównań weekendowych podgrup

Porownanie	Chi2	p_wartosc	Istotna_roznica
8:00-11:59 vs 12:00-15:59	0.0934	0.7599	nie
8:00-11:59 vs 16:00-19:59	0.0208	0.8855	nie
8:00-11:59 vs 20:00-23:59	0.6096	0.4349	nie
12:00-15:59 vs 16:00-19:59	0.0261	0.8716	nie
12:00-15:59 vs 20:00-23:59	1.1802	0.2773	nie
16:00-19:59 vs 20:00-23:59	0.8552	0.3551	nie

Na podstawie przeprowadzonych testów Walda dla wszystkich par weekendowych podgrup nie stwierdzono istotnych różnic pomiędzy predyktorami liniowymi, ponieważ we wszystkich przypadkach wartości p są większe od poziomu istotności 0.05.

Nie ma zatem podstaw do odrzucenia hipotezy zerowej H_0 , co oznacza, że intensywność napływu klientów w weekend jest taka sama w różnych blokach godzin.

Wynik ten potwierdza wcześniejsze obserwacje, że w weekend liczba klientów jest bardziej wyrównana w ciągu dnia.

Zadanie 7

Na podstawie wyników otrzymanych w zadaniu 5 planujemy optymalną liczbę pracowników oraz organizację grafiku pracy sklepu.

Zakładamy, że jeden pracownik jest w stanie obsłużyć maksymalnie 20 klientów w ciągu jednej godziny.

Dla każdej podgrupy wyznaczamy więc minimalną liczbę pracowników potrzebnych do zapewnienia sprawnej obsługi klientów.

Table 9: Minimalna liczba pracowników w poszczególnych podgrupach

Podgrupa	Średnia.liczba.klientów	Liczba.pracowników
dzień roboczy 8:00-11:59	30.01	2
dzień roboczy 12:00-15:59	19.71	1
dzień roboczy 16:00-19:59	59.64	3
dzień roboczy 20:00-23:59	29.98	2
dzień weekendowy 8:00-11:59	14.79	1
dzień weekendowy 12:00-15:59	14.95	1
dzień weekendowy 16:00-19:59	14.87	1
dzień weekendowy 20:00-23:59	14.38	1

Wnioski

Na podstawie otrzymanych wyników można zauważyć, że największa liczba pracowników jest potrzebna w dni robocze w godzinach 16 : 00–19 : 59, gdzie natężenie ruchu klientów jest najwyższe.

W pozostałych blokach godzin w dni robocze wystarczają 1–2 osoby, natomiast w weekend we wszystkich godzinach wystarczy 1 pracownik.

Oznacza to, że grafik pracy powinien przewidywać zwiększoną liczbę pracowników w godzinach popołudniowych w dni robocze, a w weekend możliwe jest utrzymanie stałej, minimalnej liczby pracowników.