

Raport 3

Dagmara Skowron

2026-04-17

Zadanie 1

Celem zadania jest zbadanie mocy testu hipotezy zerowej:

H_0 : dane pochodzą z rozkładu Poissona

przeciwko alternatywie:

H_1 : dane pochodzą z rozkładu ujemnego dwumianowego.

Do testowania wykorzystamy dwie statystyki. Pierwsza to statystyka ilorazu wiarygodności:

$$\chi^2 = -2(l_1(\hat{\beta}_1) - l_2(\hat{\beta}_2)),$$

gdzie l_i oznacza logarytm funkcji wiarygodności dla odpowiedniego modelu (Poissona lub NB).

Druga statystyka ma postać:


$$T = \frac{\hat{\alpha}}{\sqrt{\text{Var}(\hat{\alpha})}},$$

gdzie $\hat{\alpha} = \frac{1}{\hat{\theta}}$ jest odwrotnością parametru dyspersji z modelu ujemnego dwumianowego.

Na początku generujemy macierz $X \in \mathbb{R}^{1000 \times 2}$ taką, że $X_{ij} \sim \mathcal{N}(0, 1/\sqrt{1000})$. Następnie wyznaczamy predyktor liniowy $\eta = X\beta$ dla $\beta = (3, 3)$.

Na podstawie tych danych generujemy 10000 niezależnych replikacji zmiennej odpowiedzi y przy założeniu H_0 . Dla każdej replikacji dopasowujemy model Poissona oraz model ujemny dwumianowy, a następnie obliczamy wartości statystyk χ^2 oraz $\hat{\alpha}$.

Na końcu porównujemy empiryczne rozkłady tych statystyk z rozkładami teoretycznymi.




Wnioski

Rozkład empiryczny statystyki χ^2 , mimo dużej liczby wartości bliskich zeru, jest zgodny z rozkładem teoretycznym. Histogram pokazuje, że ogólny kształt rozkładu odpowiada gęstości teoretycznej.

Wykres kwantylowo-kwantylowy wskazuje, że większość kwantyli empirycznych pokrywa się z teoretycznymi. Niewielkie odchylenia pojawiają się w ogonie rozkładu, gdzie obserwujemy lekką nadreprezentację dużych wartości statystyki.

Oznacza to, że przybliżenie rozkładem χ^2 jest dobre, choć nieidealne dla największych wartości.

Poniżej znajduje się histogram i QQ-plot, które przedstawiają rozkład estymatora $\hat{\alpha}$ oraz jego zgodność z rozkładem normalnym.



Wnioski

Estymator $\hat{\alpha}$ przyjmuje wyłącznie dodatnie wartości i jest silnie skoncentrowany blisko zera. Rozkład estymatora jest wyraźnie asymetryczny prawostronnie. QQ-plot względem rozkładu normalnego pokazuje istotne odchylenia od prostej, szczególnie dla większych wartości. Wskazuje to, że rozkład estymatora $\hat{\alpha}$ nie jest zgodny z rozkładem normalnym.


Zadanie 2 i 3

Celem zadania jest wstępna analiza danych dotyczących liczby wizyt w gabinecie lekarskim oraz ocena ich podstawowych własności. W szczególności interesuje nas rozkład liczby wizyt oraz sprawdzenie, czy założenia modelu Poissona są spełnione.

W pierwszym kroku analizujemy histogram liczby wizyt, aby ocenić kształt rozkładu. Zwracamy uwagę na ewentualną asymetrię, liczbę zer oraz ogólny rozrzut danych.

Na podstawie tej analizy sprawdzamy, czy w danych występuje nadmierna dyspersja oraz czy pojawia się nadmiar zer w porównaniu do rozkładu Poissona. Wyniki tej części będą pomocne przy wyborze odpowiedniego modelu regresji w dalszej analizie.

Histogram liczby wizyt w gabinecie lekarskim








Histogram liczby wizyt w gabinecie lekarskim wskazuje na bardzo silną asymetrię prawostronną oraz dużą koncentrację obserwacji przy małych wartościach, w szczególności przy zerze. Większość pacjentów ma niewielką liczbę wizyt, natomiast tylko nieliczne osoby korzystają z opieki medycznej bardzo często, co objawia się długim prawym ogonem rozkładu.

Taki kształt rozkładu sugeruje występowanie dwóch istotnych zjawisk. Po pierwsze, widoczna jest nadmierna dyspersja, ponieważ zmienność liczby wizyt jest większa niż zakłada model Poissona. Po drugie, można zaobserwować inflację w zerze, gdyż liczba zer wydaje się większa niż oczekiwana w klasycznym modelu Poissona.

Występowanie tych zjawisk wskazuje, że model Poissona może być niewystarczający do opisu danych, a lepsze dopasowanie mogą zapewnić modele uwzględniające nadmierną dyspersję oraz nadmiar zer, takie jak NB, ZINB/ZINBR oraz model z barierą.

Aby ocenić wpływ poszczególnych zmiennych objaśniających na liczbę wizyt lekarskich, przedstawiono boxploty rozkładu przekształconej zmiennej $\log(\text{ofp} + 0.5)$ w zależności od analizowanych cech.



Wnioski:

1. Wizyty vs. Pobyty w szpitalu:

Wykres wskazuje na ogólną tendencję wzrostową – wraz ze wzrostem liczby pobyków w szpitalu rośnie liczba wizyt lekarskich. Zależność ta nie jest jednak idealnie monotoniczna, co widać np. dla wartości 5, gdzie

mediana liczby wizyt jest niższa niż dla wartości 4. Może to wynikać z mniejszej liczby obserwacji w tej grupie lub większego wpływu wartości odstających. Mimo tej nieregularności trend jest wyraźny – osoby częściej hospitalizowane mają przeciętnie więcej wizyt lekarskich, co odzwierciedla większe potrzeby zdrowotne.

2. Wizyty vs. Stan zdrowia:

Występuje wyraźna zależność – osoby w gorszym stanie zdrowia mają więcej wizyt niż osoby w stanie przeciętnym i dobrym. Zależność ta jest zgodna z intuicją – gorszy stan zdrowia wiąże się z większą potrzebą korzystania z opieki medycznej.

3. Wizyty vs. Stany przewlekłe:

Widoczna jest silna dodatnia zależność – im więcej chorób przewlekłych, tym więcej wizyt lekarskich. Spadek dla najwyższej kategorii (8) może wynikać z małej liczby obserwacji lub specyfiki tej grupy pacjentów (np. korzystanie częściej z hospitalizacji).

4. Wizyty vs. Płeć:

Nie obserwuje się istotnych różnic między kobietami a mężczyznami. Mediany liczby wizyt są bardzo zbliżone, choć rozrzut danych dla mężczyzn jest nieco większy. Sugeruje to, że płeć nie jest kluczowym czynnikiem wpływającym na liczbę wizyt w analizowanej próbie.

5. Wizyty vs. Wykształcenie:

Widoczna jest delikatna tendencja wzrostowa – osoby z wyższym wykształceniem mają nieco więcej wizyt lekarskich. Różnice nie są jednak duże. Może to wynikać z większej świadomości zdrowotnej i częstszego korzystania z usług medycznych przez osoby lepiej wykształcone.

6. Wizyty vs. Ubezpieczenie prywatne:

Osoby posiadające prywatne ubezpieczenie mają nieco wyższą medianę liczby wizyt niż osoby bez ubezpieczenia. Różnica nie jest bardzo duża, ale może wskazywać na łatwiejszy dostęp do opieki medycznej lub mniejsze ograniczenia finansowe.

Podsumowanie

Na podstawie analizy wykresów można stwierdzić, że liczba wizyt lekarskich najsilniej zależy od liczby pobyków w szpitalu oraz liczby stanów przewlekłych, a także od stanu zdrowia pacjenta. Czynniki takie jak wykształcenie i ubezpieczenie prywatne, mają mniejszy, ale zauważalny wpływ. Płeć wydaje się mieć najmniejsze znaczenie.

Zadanie 4

Celem zadania jest dopasowanie różnych modeli regresji dla danych oraz porównanie ich jakości dopasowania. W szczególności sprawdzamy, który model najlepiej opisuje liczbę wizyt w gabinecie lekarskim.

Rozważamy kilka modeli: model Poissona, model ujemny dwumianowy oraz modele uwzględniające nadmiar zer (zero-inflated oraz modele z barierą). Następnie, tam gdzie jest to uzasadnione, upraszczamy modele poprzez usunięcie nieistotnych zmiennych.

Na końcu porównujemy modele za pomocą wybranych kryteriów, takich jak logarytm funkcji wiarygodności, AIC oraz BIC, a także sprawdzamy, jak dobrze odwzorowują liczbę zer w danych. Na tej podstawie wybieramy model, który najlepiej pasuje do analizowanych danych.

Table 1: Porównanie modeli regresji

Parametr	Poisson	NB	ZIPR	ZINBR	Pois_hurdle	NB_hurdle
Alpha (dyspersja)		0.8288		0.6732		0.7166
Liczba parametrow	8	9	14	14	14	15
log-likelihood	-17971.61	-12170.55	-16135.24	-12094.25	-16136.44	-12090.07
AIC	35959.23	24359.11	32298.49	24216.51	32300.88	24210.14
BIC	36010.35	24416.62	32387.96	24305.98	32390.35	24306
Oczekiwana liczba zer	46.71	608.01	682.3	707.22	683	683
Usuniete zmienne	brak	brak	health (infl.)	hosp, health (infl.)	health (zero)	health (zero)

Wnioski

1. Nadmierna dyspersja:

W modelach ujemnych dwumianowych (NB, ZINBR, NB_hurdle) parametr dyspersji α jest dodatni, co wskazuje na występowanie nadmiernej dyspersji w danych. Oznacza to, że wariancja liczby wizyt jest większa niż jej wartość oczekiwana, dlatego model Poissona nie jest wystarczający do ich opisu.

2. Jakość dopasowania modeli:

Modele ujemne dwumianowe oraz modele uwzględniające nadmiar zer (ZINBR, NB_hurdle) mają wyższe wartości log-likelihood oraz niższe wartości AIC i BIC niż model Poissona, co świadczy o ich lepszym dopasowaniu do danych.

3. Modelowanie nadmiaru zer:

Model Poissona wyraźnie zaniża przewidywaną liczbę zer w danych. Modele NB poprawiają to dopasowanie, jednak dopiero modele zero-inflated oraz hurdle dobrze odwzorowują rzeczywistą liczbę zer.

4. Porównanie modeli:

Spośród wszystkich modeli najlepsze wyniki uzyskują modele NB, ZINBR oraz NB_hurdle. Szczególnie model NB_hurdle charakteryzuje się najlepszym dopasowaniem (najwyższy log-likelihood oraz najniższe AIC i BIC) oraz dobrze odtwarza liczbę zer.

5. Wybór najlepszego modelu:

Na podstawie wszystkich kryteriów najlepszym modelem dla analizowanych danych jest model ujemny dwumianowy z barierą (NB_hurdle). Uwzględnia on zarówno nadmierną dyspersję, jak i nadmiar zer, co pozwala najlepiej opisać strukturę danych.