

Raport 4

Dagmara Skowron

2026-05-04

Wstęp

Celem raportu jest analiza modeli liniowych dla danych z pomiarami wielokrotnymi. W takich danych dla każdego obiektu wykonuje się kilka pomiarów. Oznacza to, że obserwacje pochodzące od tego samego obiektu mogą być ze sobą skorelowane.

W raporcie generowane są dane zgodnie z podanym modelem. Następnie dopasowywany jest uogólniony model liniowy za pomocą funkcji `gls()` z pakietu `nlme`.

W kolejnych zadaniach porównywane są estymatory parametrów modelu. Analizowane są estymatory wektora parametrów `beta`, parametru korelacji `rho` oraz parametru skali `gamma`. Sprawdzane jest także, jak na wyniki wpływa liczba obiektów, liczba pomiarów dla jednego obiektu oraz liczba predyktorów.

Zadanie 1

W tym zadaniu generujemy dane dla modelu z pomiarami wielokrotnymi. Przyjmujemy, że liczba obiektów wynosi $n = 20$, liczba pomiarów dla każdego obiektu wynosi $k = 3$, a liczba parametrów w modelu wynosi $p = 4$.

a) Generowanie macierzy **X** i macierzy kowariancji **Sigma**

W pierwszym kroku ustalamy parametry zadania. Następnie generujemy macierz zmiennych objaśniających **X**. Definiujemy także wartości parametrów `rho` i `gamma`, które są potrzebne do zbudowania macierzy kowariancji **Sigma**.

Table 1: Pierwsze wiersze macierzy **X**

x1	x2	x3
-0.072357	0.049011	0.015188
-0.029716	-0.064850	-0.122318
0.201228	-0.043017	-0.063331
0.009103	-0.131498	-0.033061
0.016691	-0.138368	0.238042
0.221414	0.039185	-0.084166

Table 2: Macierz kowariancji **Sigma**

4.0	1.2	1.2
1.2	4.0	1.2
1.2	1.2	4.0

Elementy macierzy X są małe, ponieważ pochodzą z rozkładu normalnego o wariancji $1/N$.

Macierz kowariancji Σ ma wartości 4 na przekątnej oraz 1.2 poza przekątną. Jest to zgodne z przyjętymi wartościami $\gamma = 2$ oraz $\rho = 0.3$.

b) Generowanie danych i dopasowanie modelu GLS

W tej części generujemy zmienną zależną y . Dane zapisujemy w jednowymiarowej reprezentacji, czyli w jednej tabeli znajdują się wartości y , numer obiektu id , numer pomiaru T oraz zmienne objaśniające.

Następnie dopasowujemy model `gls()` metodą **REML**.

Table 3: Pierwsze wiersze danych w jednowymiarowej reprezentacji

y	id	T	x1	x2	x3
3.208889	1	1	-0.072357	0.049011	0.015188
0.820183	1	2	-0.029716	-0.064850	-0.122318
0.751090	1	3	0.201228	-0.043017	-0.063331
0.574158	2	1	0.009103	-0.131498	-0.033061
1.293844	2	2	0.016691	-0.138368	0.238042
1.974068	2	3	0.221414	0.039185	-0.084166

Table 4: Estymatory parametrów modelu GLS

parametr	estymator	blad_standardowy
(Intercept)	-0.007359	0.291881
x1	2.638830	1.948358
x2	3.249395	2.034237
x3	-0.237491	1.692039

Dane zostały zapisane w jednowymiarowej reprezentacji. Każdy wiersz odpowiada jednemu pomiarowi dla danego obiektu.

Model GLS został dopasowany metodą **REML**. W modelu uwzględniono korelację między pomiarami pochodzącymi od tego samego obiektu.

Estymatory parametrów $x1$ i $x2$ są dodatnie, co jest zgodne z tym, że prawdziwe wartości tych parametrów wynoszą 3. Estymator parametru $x3$ jest bliski zeru, co też jest zgodne z założeniami modelu.

c) Porównanie estymatorów

W tej części porównujemy estymator wektora β otrzymany z modelu `gls()` z estymatorem obliczonym ręcznie za pomocą wzorów macierzowych. Porównujemy także macierze kowariancji estymatora β .

Table 5: Porównanie estymatorów β

Parametr	Estymator z modelu	Estymator ręczny	Różnica
(Intercept)	-0.007359	-0.007359	0
x1	2.638830	2.638830	0
x2	3.249395	3.249395	0
x3	-0.237491	-0.237491	0

Table 6: Normy supremum różnic dla estymatorów beta

wielkosc	wartosc
Norma supremum różnicy estymatorów beta	0
Norma supremum różnicy macierzy kowariancji beta	0

Następnie porównujemy prawdziwe wartości parametrów **rho** i **gamma** z ich estymatorami otrzymanymi z modelu.

Table 7: Porównanie parametrów rho i gamma z ich estymatorami

parametr	wartosc_prawdziwa	estymator	roznica	norma_supremum
rho	0.3	0.242592	0.057408	0.057408
gamma	2.0	1.850409	0.149591	0.149591

Estymatory **beta** otrzymane z modelu `gls()` są praktycznie takie same jak estymatory obliczone ręcznie.

Macierz kowariancji estymatora **beta** obliczona ręcznie jest zgodna z macierzą zwracaną przez funkcję `vcov()`.

Estymatory **rho** i **gamma** różnią się od wartości prawdziwych. Jest to naturalne, ponieważ zostały wyznaczone na podstawie jednej losowo wygenerowanej próby.

Zadanie 2

W tym zadaniu wykonujemy symulację. Najpierw generujemy jedną macierz **X**, tak jak w zadaniu 1. Następnie dla tej samej macierzy **X** generujemy 500 różnych wektorów zmiennej zależnej **y**.

Dla każdego wygenerowanego zestawu danych dopasowujemy model `gls()` metodą REML. W ten sposób otrzymujemy 500 estymatorów wektora **beta**, 500 estymatorów parametru **rho** oraz 500 estymatorów parametru **gamma**.

Na podstawie tych wyników analizujemy asymptotyczne własności estymatorów. Rysujemy histogramy wybranych estymatorów, obliczamy ich obciążenie oraz tworzymy tabele podsumowujące wyniki.

Symulacja 500 modeli

```
## Liczba poprawnie dopasowanych modeli: 500
```

Table 8: Obciążenie estymatorów beta

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
(Intercept)	0	0.008473	0.008473
x1	3	3.025235	0.025235
x2	3	3.054639	0.054639
x3	0	-0.041630	-0.041630

Table 9: Norma supremum obciążenia estymatora beta

wielkosc	wartosc
Norma supremum obciążenia estymatora beta	0.054639

Table 10: Obciążenie estymatorów rho i gamma

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
rho	0.3	0.300139	0.000139
gamma	2.0	2.000750	0.000750

Histogramy estymatorów

Poniżej przedstawiono histogramy estymatorów `beta_0`, `beta_1`, `rho` oraz `gamma`. Zielona linia pionowa oznacza wartość prawdziwą parametru. Dla estymatorów `beta` dodatkowo narysowano czerwoną krzywą odpowiadającą asymptotycznemu rozkładowi normalnemu.




Table 11: Podsumowanie obciążeń estymatorów

parametr	wartosc
beta - norma supremum obciążenia	0.054639
rho - obciążenie	0.000139
gamma - obciążenie	0.000750

Wnioski

Na podstawie 500 powtórzeń można ocenić zachowanie estymatorów w wielu losowych próbach. Estymatory parametrów `beta` są średnio bliskie wartościom prawdziwym. Estymator `beta_0` jest skupiony wokół wartości 0, a estymator `beta_1` wokół wartości 3.

Histogramy estymatorów **beta_0** oraz **beta_1** mają kształt zbliżony do rozkładu normalnego. Jest to zgodne z asymptotycznymi własnościami estymatorów w modelach liniowych.

Estymatory **rho** oraz **gamma** również są skupione blisko wartości prawdziwych. Widać jednak, że estymator **rho** ma dość dużą zmienność. Wynika to z tego, że parametry struktury kowariancji są trudniejsze do dokładnego oszacowania, szczególnie przy małej liczbie obiektów.

Zadanie 3

W tym zadaniu sprawdzamy wpływ liczby obiektów na jakość estymacji. Powtarzamy symulację z zadania 2, ale zwiększamy liczbę obiektów z $n = 20$ do $n = 100$.

Pozostałe parametry pozostają bez zmian: $k = 3$, $p = 4$, $\rho = 0.3$ oraz $\gamma = 2$. Dla każdej z 500 prób generujemy nowy wektor zmiennej zależnej y , dopasowujemy model `glis()` metodą REML i zapisujemy estymatory **beta**, **rho** oraz **gamma**.

Celem jest sprawdzenie, czy większa liczba obiektów poprawia dokładność estymacji.

Table 12: Liczba poprawnie dopasowanych modeli

opis	wartosc
Liczba poprawnie dopasowanych modeli	500

Table 13: Obciążenie estymatorów beta dla $n = 100$

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
(Intercept)	0	0.002683	0.002683
x1	3	2.995571	-0.004429
x2	3	2.780153	-0.219847
x3	0	-0.137923	-0.137923

Table 14: Norma supremum obciążenia estymatora beta dla $n = 100$

wielkosc	wartosc
Norma supremum obciążenia estymatora beta	0.219847

Table 15: Obciążenie estymatorów rho i gamma dla $n = 100$

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
rho	0.3	0.298929	-0.001071
gamma	2.0	2.002669	0.002669

Histogramy estymatorów

Poniżej przedstawiono histogramy estymatorów **beta_0**, **beta_1**, **rho** oraz **gamma** dla $n = 100$.




Table 16: Podsumowanie obciążeń estymatorów

parametr	wartosc
beta - norma supremum obciążenia	0.219847
rho - obciążenie	-0.001071
gamma - obciążenie	0.002669

Wnioski

Po zwiększeniu liczby obiektów do $n = 100$ estymatory parametrów **rho** i **gamma** są bardzo bliskie wartościom prawdziwym. Obciążenie estymatora **rho** jest bliskie zeru, a obciążenie estymatora **gamma** jest bardzo małe.

Estymatory **beta_0** i **beta_1** również są średnio bliskie wartościom prawdziwym. Dla parametrów **x2** i **x3** widać większe odchylenia od wartości prawdziwych. Może to wynikać z konkretnej wylosowanej macierzy **X**, która w tej symulacji była ustalona dla wszystkich 500 powtórzeń.

Histogramy pokazują, że rozkłady estymatorów są skupione wokół wartości prawdziwych. W porównaniu z zadaniem 2 szczególnie poprawiła się estymacja parametrów **rho** i **gamma**. Oznacza to, że zwiększenie liczby obiektów poprawia dokładność estymacji.

Zadanie 4

W tym zadaniu sprawdzamy wpływ liczby pomiarów wykonanych dla każdego obiektu. Powtarzamy symulację z zadania 2, ale zwiększamy liczbę pomiarów z $k = 3$ do $k = 15$.

Pozostałe parametry pozostają bez zmian: $n = 20$, $p = 4$, $\rho = 0.3$ oraz $\gamma = 2$. Dla każdej z 500 prób generujemy nowy wektor zmiennej zależnej y , dopasowujemy model `gls()` metodą REML i zapisujemy estymatory `beta`, `rho` oraz `gamma`.

Celem jest sprawdzenie, czy większa liczba pomiarów w obrębie każdego obiektu poprawia jakość estymacji.

Table 17: Liczba poprawnie dopasowanych modeli

opis	wartosc
Liczba poprawnie dopasowanych modeli	500

Table 18: Obciążenie estymatorów `beta` dla $k = 15$

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
(Intercept)	0	0.001294	0.001294
x1	3	3.035400	0.035400
x2	3	2.954751	-0.045249
x3	0	-0.010370	-0.010370

Table 19: Norma supremum obciążenia estymatora `beta` dla $k = 15$

wielkosc	wartosc
Norma supremum obciążenia estymatora <code>beta</code>	0.045249

Table 20: Obciążenie estymatorów `rho` i `gamma` dla $k = 15$

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
<code>rho</code>	0.3	0.292966	-0.007034
<code>gamma</code>	2.0	1.999657	-0.000343

Histogramy estymatorów

Poniżej przedstawiono histogramy estymatorów `beta_0`, `beta_1`, `rho` oraz `gamma` dla $k = 15$.




Table 21: Podsumowanie obciążeń estymatorów

parametr	wartosc
beta - norma supremum obciążenia	0.045249
rho - obciążenie	-0.007034
gamma - obciążenie	-0.000343

Wnioski

Po zwiększeniu liczby pomiarów do $k = 15$ estymatory parametrów **beta** są średnio bliskie wartościom prawdziwym. Norma supremum obciążenia estymatora **beta** jest mała, co oznacza dobrą jakość estymacji.

Estymatory **rho** i **gamma** również są bliskie wartościom prawdziwym. Szczególnie estymator **gamma** ma bardzo małe obciążenie.

Histogramy pokazują, że rozkłady estymatorów są skupione wokół wartości prawdziwych. Zwiększenie liczby pomiarów dla każdego obiektu daje więcej informacji o zależnościach wewnątrz obiektu. Dzięki temu poprawia się estymacja struktury kowariancji oraz stabilność estymatorów.

Zadanie 5

W tym zadaniu sprawdzamy wpływ liczby predyktorów na jakość estymacji. Powtarzamy symulację z zadania 2, ale zwiększamy liczbę parametrów w modelu do $p = 20$.

Oznacza to, że w macierzy planu znajduje się więcej zmiennych objaśniających. Pozostałe parametry pozostają bez zmian: $n = 20$, $k = 3$, $\rho = 0.3$ oraz $\gamma = 2$.

Dla każdej z 500 prób generujemy nowy wektor zmiennej zależnej y , dopasowujemy model `glms()` metodą REML i zapisujemy estymatory `beta`, `rho` oraz `gamma`.

Celem jest sprawdzenie, czy większa liczba predyktorów wpływa na stabilność estymatorów.

Table 22: Liczba poprawnie dopasowanych modeli

opis	wartosc
Liczba poprawnie dopasowanych modeli	500

Table 23: Obciążenie estymatorów β dla $p = 20$

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
(Intercept)	0	-0.023715	-0.023715
x1	3	3.104311	0.104311
x2	3	3.001544	0.001544
x3	0	-0.024625	-0.024625
x4	0	-0.105639	-0.105639
x5	0	-0.062888	-0.062888
x6	0	-0.117538	-0.117538
x7	0	0.052439	0.052439
x8	0	0.044332	0.044332
x9	0	-0.003350	-0.003350
x10	0	-0.099472	-0.099472
x11	0	0.015462	0.015462
x12	0	-0.198193	-0.198193
x13	0	0.003583	0.003583
x14	0	0.000587	0.000587
x15	0	0.024456	0.024456
x16	0	0.049845	0.049845
x17	0	-0.094522	-0.094522
x18	0	-0.050858	-0.050858
x19	0	-0.079021	-0.079021

Table 24: Norma supremum obciążenia estymatora β dla $p = 20$

wielkosc	wartosc
Norma supremum obciążenia estymatora β	0.198193

Table 25: Obciążenie estymatorów ρ i γ dla $p = 20$

parametr	wartosc_prawdziwa	srednia_estymatora	obciazenie
ρ	0.3	0.290654	-0.009346
γ	2.0	1.999461	-0.000539

Histogramy estymatorów

Poniżej przedstawiono histogramy estymatorów `beta_0`, `beta_1`, `rho` oraz `gamma` dla $p = 20$.




Table 26: Podsumowanie obciążeń estymatorów

parametr	wartość
beta - norma supremum obciążenia	0.198193
rho - obciążenie	-0.009346
gamma - obciążenie	-0.000539

Porównanie zadań 2, 3, 4 i 5

W tej części zestawiamy wyniki zadań 2–5, aby porównać wpływ liczby obiektów, liczby pomiarów oraz liczby predyktorów.

Table 27: Porównanie wyników dla zadań 2, 3, 4 i 5

wariant	beta_sup_norm_bias	rho_bias	gamma_bias
Zadanie 2: $n = 20$, $k = 3$, $p = 4$	0.054639	0.000139	0.000750
Zadanie 3: $n = 100$, $k = 3$, $p = 4$	0.219847	-0.001071	0.002669
Zadanie 4: $n = 20$, $k = 15$, $p = 4$	0.045249	-0.007034	-0.000343
Zadanie 5: $n = 20$, $k = 3$, $p = 20$	0.198193	-0.009346	-0.000539

Wnioski

Po zwiększeniu liczby predyktorów do $p = 20$ model ma więcej parametrów do oszacowania. Liczba obserwacji nie zwiększa się w takim samym stopniu, dlatego estymacja parametrów **beta** jest mniej stabilna.

Norma supremum obciążenia estymatora **beta** jest większa niż w zadaniu 2 i zadaniu 4. Oznacza to, że dodanie wielu predyktorów może pogorszyć dokładność estymacji współczynników regresji.

Estymatory **rho** i **gamma** pozostają bliskie wartościom prawdziwym. Ich obciążenia są małe, więc zwiększenie liczby predyktorów nie pogorszyło wyraźnie estymacji struktury kowariancji.

Porównanie zadań 2–5 pokazuje, że zwiększenie liczby pomiarów lub liczby obiektów może poprawiać dokładność estymacji. Zwiększenie liczby predyktorów może natomiast utrudniać estymację parametrów **beta**.

Zadanie 6

W tym zadaniu powtarzamy analizy z zadań 2–5, ale zmieniamy metodę estymacji. Zamiast metody REML stosujemy metodę największej wiarygodności, czyli ML.

Dla każdego wariantu wykonujemy 500 symulacji. W każdej symulacji generujemy nowy wektor zmiennej zależnej y , dopasowujemy model `gls()` metodą ML i zapisujemy estymatory parametrów **beta**, **rho** oraz **gamma**.

Celem jest porównanie wyników uzyskanych metodą ML z wynikami uzyskanymi wcześniej metodą REML.

Symulacje metodą ML

Table 28: Liczba poprawnie dopasowanych modeli metodą ML

wariant	liczba_modeli
ML: $n = 20$, $k = 3$, $p = 4$	500
ML: $n = 100$, $k = 3$, $p = 4$	500
ML: $n = 20$, $k = 15$, $p = 4$	500
ML: $n = 20$, $k = 3$, $p = 20$	500


Table 29: Porównanie wyników dla metody ML

wariant	beta_sup_norm_bias	rho_bias	gamma_bias
Zadanie 2: $n = 20$, $k = 3$, $p = 4$	0.105918	-0.005940	-0.083533
Zadanie 3: $n = 100$, $k = 3$, $p = 4$	0.143512	-0.005770	-0.018698
Zadanie 4: $n = 20$, $k = 15$, $p = 4$	0.068246	-0.015542	-0.030514
Zadanie 5: $n = 20$, $k = 3$, $p = 20$	0.233890	0.074396	-0.273131

Table 30: Porównanie metod REML i ML

metoda	wariant	beta_sup_norm_bias	rho_bias	gamma_bias
REML	Zadanie 2: $n = 20$, $k = 3$, $p = 4$	0.054639	0.000139	0.000750
REML	Zadanie 3: $n = 100$, $k = 3$, $p = 4$	0.219847	-0.001071	0.002669
REML	Zadanie 4: $n = 20$, $k = 15$, $p = 4$	0.045249	-0.007034	-0.000343
REML	Zadanie 5: $n = 20$, $k = 3$, $p = 20$	0.198193	-0.009346	-0.000539
ML	Zadanie 2: $n = 20$, $k = 3$, $p = 4$	0.105918	-0.005940	-0.083533
ML	Zadanie 3: $n = 100$, $k = 3$, $p = 4$	0.143512	-0.005770	-0.018698
ML	Zadanie 4: $n = 20$, $k = 15$, $p = 4$	0.068246	-0.015542	-0.030514
ML	Zadanie 5: $n = 20$, $k = 3$, $p = 20$	0.233890	0.074396	-0.273131

Poniżej przedstawiono histogramy estymatorów dla podstawowego wariantu $n = 20$, $k = 3$, $p = 4$, ale z użyciem metody ML.



Wnioski

Wyniki dla metody ML różnią się od wyników otrzymanych metodą REML. Największe różnice są widoczne dla estymatora parametru **gamma**, czyli parametru związanego ze skalą macierzy kowariancji.

Metoda ML daje ujemne obciążenie estymatora **gamma**. Oznacza to, że średnie wartości tego estymatora są mniejsze od wartości prawdziwej. Jest to zgodne z teorią, ponieważ metoda ML nie uwzględnia utraty stopni swobody związanej z estymacją parametrów **beta**.

Dla większej liczby obiektów, czyli w wariancie $n = 100$, różnice między metodami ML i REML są mniejsze. Oznacza to, że przy większej próbie obie metody dają bardziej podobne wyniki.

Największe pogorszenie dla metody ML widać w wariancie z większą liczbą predyktorów, czyli dla $p = 20$. W tym przypadku obciążenie estymatora **gamma** jest największe. Wynika to z tego, że model estymuje dużo parametrów przy stosunkowo małej liczbie obserwacji.

Podsumowując, metoda REML lepiej sprawdza się przy estymacji parametrów kowariancji, szczególnie w małych próbach i przy większej liczbie predyktorów.